ETF 교육 콘텐츠 개인화 추천 시스템

목적과 진단 수준에 맞춘 학습 경로와 다음 단원 추천

인공지능과추천시스템 중간보고서
작성자 ○○○ 학번 ○○○○○○○○

초·중급 개인투자자에게 투자 목적·진단 수준·선수 이수 상태에 맞는 ETF 교육 단원을 주 5 개 이내로 추천한다. 적용 기법은 목적 단계 규칙이며, 관심·수준·기기에 목적 친화도와 현재 로드맵 단계의 가산점을 결합한다. 모든 비교 기법에 공통 수준·선수 필터를 적용하고, 모의 학습자 15,000 명 자료에서 NDCG@5 와 목적·현재 단계 정합률로 평가한다. 모의 데이터에서 운영안의 NDCG@5 는 인구통계를 쓰는 검증 선택 규칙보다 낮고 나머지 비교군보다 소폭 높았다. 공통 기초 이수를 가정한 운영안의 정합률은 비교군보다 12%p 이상 높았다. 모의 진단에 따른 후보 변화와 목적별 추천 사례를 제시하며, 모의 결과는 추천 절차의 작동 범위를 점검하는 자료로 활용한다. 11~12 월 파일럿에서는 실제 진단·학습 기록을 수집해 문항과 이수 인정의 타당성을 검토한다.

1 추천 기법 요약 및 한계점

수업에서 다룬 여섯 기법의 핵심 원리·장점·한계점을 비교한다. 각 기법이 사용하는 정보와 점수 산출 원리를 정리하고, 신규 사용자 대응, 설명 가능성, 계산 비용, 신규 아이템 처리의 차이를 살핀다. 기본형의 특성과 초기화·후처리 같은 서비스 설계를 구분해 적용 가능성을 판단한다. 반응 정보와 기법의 기본 원리는 관련 연구와 수업 교안을 참고했다[4][5].

표 1 여섯 추천 기법의 기본 원리와 장단점

기법	핵심 원리	장점	한계점
인기 기반	전체 사용자의 조회·구매·평점 등 반응을 아이템별로 집계하고 큰 값부터 제시한다. 집단 인기는 사용자 집단별로 집계한 변형이다. 표본이 적은 집단은 전체 인기 쪽으로 보정할 수 있다.	개인 이력이 없는 사용자에게도 목록을 제시한다. 구현·설명이 간단하고 다른 기법의 성능을 판단할 기준선으로 쓰기 좋다.	전체 인기는 사용자별 목적·수준을 구분하지 못한다. 인기 아이템에 노출이 몰리고, 새 아이템은 관측을 쌓기 어렵다. 집단 인기도 개인 수준의 요구를 완전히 설명하지 못한다.
규칙 기반	사용자의 요구와 아이템 속성에 대해 미리 정한 조건·가중치를 적용해 점수나 우선순위를 결정한다. 예를 들어 관심 주제와 일치하면 가산점을 주고, 조건을 충족하지 못하면 후보에서 제외한다.	진단·입력만으로 초기 추천을 시작할 수 있다. 조건별 기여를 설명하기 쉽고, 교육 목적이나 필수 제약을 명시적으로 반영하기 쉽다.	규칙과 가중치 설계에 의존한다. 새로운 상황에 맞춰 사람이 갱신·검증해야 하며, 가산점만으로 선수 순서를 보장할 수는 없다. 규칙 수가 늘면 충돌과 유지보수 부담이 커진다.
콘텐츠 기반	아이템의 주제·텍스트·속성을 특징 벡터로 표현한다. 사용자가 반응한 아이템 특징을 결합해 사용자 프로필을 만들고, 후보와 프로필의 유사도로 추천한다.	다른 사용자의 반응 없이 개인화할 수 있다. 특징이 준비된 새 아이템에도 점수를 줄 수 있고, 유사한 속성을 추천 이유로 설명할 수 있다.	특징의 품질과 사용자 프로필 구성에 민감하다. 유사한 내용에 치우쳐 새로운 관심을 발견하기 어렵다. 이력만 쓰는 기본형은 신규 사용자 프로필을 만들 수 없어 별도 초기화가 필요하다.

기법	핵심 원리	장점	한계점
사용자 기반 CF	사용자–아이템 반응 벡터로 비슷한 사용자를 찾고, 이웃의 반응을 유사도로 가중 평균해 아직 경험하지 않은 아이템의 선호를 추정한다. 코사인 유사도·최근접 이웃 수 등이 핵심 설정이다.	아이템 속성을 상세히 설계하지 않아도 공동 행동을 활용한다. 비슷한 사용자가 좋아한, 본인의 기존 관심 밖 아이템을 발견할 수 있다.	겹치는 관측이 적으면 이웃 유사도가 불안정하다. 신규 사용자와 신규 아이템에 약하며, 사용자 수가 커질수록 이웃 탐색 비용이 늘어난다. 인구통계 유사도 혼합은 기본형과 구분해야 한다.
아이템 기반 CF	같은 사용자에게 함께 반응이 발생한 아이템 사이의 유사도를 구한다. 사용자가 반응한 아이템과 후보의 유사도를 합산하거나 가중 평균해 점수를 만든다. 공동 관측이 적으면 유사도를 보정할 수 있다.	아이템 간 관계를 사전 계산·캐시해 요청 시 계산량을 줄일 수 있다. 사용자 집단이 자주 바뀌는 상황에서도 비교적 안정된 아이템 관계를 활용하고 관련 아이템을 설명하기 쉽다.	새 아이템은 공동 관측이 없어 유사도 계산이 어렵다. 신규 사용자도 결합할 이력이 없다. 인기 아이템에 치우치고, 아이템 수가 매우 크면 유사도 행렬의 저장·계산 비용이 커진다.
행렬분해 MF	반응 행렬을 사용자 잠재요인 행렬과 아이템 잠재요인 행렬의 곱으로 근사한다. 점수는 두 벡터의 내적이며, 기본형은 관측값의 제곱오차와 규제항의 합을 최소화해 요인을 학습한다.	충분한 기록이 있으면 직접 드러나지 않은 공동 선호를 저차원 요인으로 표현한다. 학습 이후 내적으로 빠르게 점수를 계산하며 대규모 자료에 확장하기 좋다.	신규 사용자·아이템의 요인을 추정하기 어렵고 잠재요인의 의미를 직접 설명하기 어렵다. 점별 제곱오차는 상위 순위를 직접 최적화하지 않으며, 미관측을 실제 비선호로 해석해서는 안 된다.

표 2 기본형의 적용 조건 비교

기법	신규 사용자	설명 가능성	계산 특성	핵심 운영 과제
인기 기반	가능	집계·조건 설명 가능	집계 후 빠름	개인 목적 차이를 구분하지 못함
규칙 기반	입력·진단이 있으면 가능	조건별 설명 가능	규칙 수가 적으면 빠름	규칙·가중치의 지속적 갱신
콘텐츠 기반	기본형은 곤란	특징 유사도로 가능	프로필·특징 검색 필요	새 아이템은 특징이 있으면 가능
사용자 CF	기본형은 곤란	비슷한 사용자로 부분 가능	사용자·이웃 수에 영향	새 사용자·새 아이템 모두 취약
아이템 CF	기본형은 곤란	함께 반응한 아이템으로 가능	사전 계산·캐시 활용	새 아이템 공동 관측 부족
MF	기본형은 곤란	잠재요인만으로는 곤란	학습 후 내적은 빠름	양쪽 요인의 초기화 필요

표 2 의 신규 사용자 평가는 행동 이력이 없는 경우를 뜻한다. 콘텐츠·CF·MF 의 초기 추천에는 인기 순위 대체나 설문 기반 프로필 초기화 같은 별도 전략이 필요하다. 설명 가능성은 점수의 근거를 전달하는 성질이며, 교육 순서의 준수에는 후보 자격을 검사하는 필수 제약이 함께 필요하다.

교육 추천은 학습자의 선호와 현재 학습 준비 조건을 함께 고려해야 한다. 인기·콘텐츠·CF·MF·규칙 기반 모두 수준과 선수 이수 여부를 별도로 검사한다.

2 해결하고자 하는 문제와 추천 시나리오

2.1 해결할 문제

해결할 문제는 학습 경로의 연결이다. 초·중급 투자자는 비용·괴리율·분배금·환헤지·일간 레버리지·계좌별 과세를 어떤 순서로 공부할지 결정해야 한다. 기관별 교육과정에서 자신의 목적, 이미 아는 내용, 지금 배울 준비가 된 단원을 연결해 선택할 필요가 있다. 본 시스템은 이 세 조건을 반영해 다음 학습 단원을 제시한다.

금융위원회는 2026 년 5 월 삼성전자·SK 하이닉스를 기초로 한 단일종목 레버리지 상품(ETF·ETN) 출시와 관련해 개별기업 집중·레버리지·음의 복리·괴리율 위험을 경고했다[1].

2.2 대상 사용자

대상은 ETF 를 시작하거나 이미 일부 거래하지만 구조·위험 설명에 자신이 없는 초·중급 개인투자자다. 증권사 앱 또는 금융교육 플랫폼의 학습 메뉴에서, 출퇴근 시간 등에 짧게 공부하는 상황을 가정한다.

2.3 추천 아이템

순위를 매기는 추천 아이템은 교육 단원 66 개다. 22 개 주제에 세 수준을 두고, 선수 관계 80 개를 연결했다. 수준명은 1 기초, 2 구조·계산, 3 심화·위험으로 구분한다. 로드맵의 공통 기초·목적별 핵심·심화 단계는 학습 순서상의 구간이며, 지식 수준과 별도의 축이다. 목적별 전체 경로의 단계 구성과 현재 추천 가능한 난이도를 구분한다.

사용자가 보는 출력은 최대 다섯 단원과 단원별 이유·출처다. 로드맵은 추천의 배경과 잠김 조건을 보여 주는 안내 구조다. ETF 유형 카드 10 종은 목적→유형 템플릿 및 관련 개념의 이수 여부로 여는 교육용 고정 안내다. 알고리즘의 순위 산출과 NDCG 평가는 교육 단원을 대상으로 한다.

2.4 구체적인 사용 상황

A 는 IRP 에 무엇을 담을지 몰라 앱 학습 메뉴에 들어와, 진단 뒤 출퇴근길에는 추천 목록 중 8 분짜리 단원을 골라 하나씩 학습하고 퀴즈를 푼다.

사용 흐름은 목적·기간·위험성향 입력 → 20 문항 진단 → 이수 인정과 수준 확인 → 목적별 로드맵 확인 → 가능한 단원 중 주간 최대 다섯 개 추천 → 학습·퀴즈 → 다음 추천 갱신이다. A 는 연금·노후 목적의 안정 성향 사용자, B 는 배당·인컴 목적의 구조·계산 수준 사용자, C 는 단기 매매에 관심이 있는 기초 수준 사용자로 설정한다. 아래 수치는 각 입력에 따른 모의 페르소나의 추천 결과다.

진단 20 문항은 총 18 개 단원에 연결된다. 이수 인정용 19 문항은 중복을 합쳐 최대 17 개 단원을 판정하고, 같은 단원의 문항 두 개는 모두 응답·정답일 때만 한 단원을 인정한다. 규제 상식 한 문항은 수준 판정에만 사용한다. 정답 문항 수와 인정 단원 수를 함께 제시하고, 판정된 단원 목록으로 이수 인정의 근거를 확인한다.

공통 기초는 상품을 고르기 전에 오해를 줄이는 위험 이해를 위한 필수 과정이다. 연금 목적의 A 에게 레버리지 구조의 위험 이해는 IRP 편입 상품의 선택과 구분되는 공통 교육이다. 자체 진단·퀴즈는 학습 배치와 복습에 사용하며, 공식 사전교육과 거래 요건은 해당 제도에 따라 별도로 확인한다.

개인화는 같은 시점에서 A·B·C 의 가능한 단원과 추천 순서를 비교해 보여 준다. 진단 직후에는 공통 미이수 단원이 상위에 중복될 수 있다. 공통 위험 기초를 마친 시점의 목록도 함께 제시해 목적별 차이를 살핀다. 두 시점의 진행률·잔여 분량·점수 설명은 각각 같은 상태의 A 를 기준으로 표시한다.

표 3 같은 주차의 모의 사용자와 진단 직후 상태

사용자	목적과 입력	정답→이수 인정	수준과 후보	로드맵 진행률
A	연금·노후 / 안정 / 장기 관심 연금계좌·자산배분	7/20 → 6 단원	수준 1 후보 18	6/25 24.0%
B	배당·인컴 / 중간 위험 관심 분배금·커버드콜	13/20 → 13 단원	수준 2 후보 23	10/23 43.5%
C	단기 매매 / 높은 위험 관심 섹터·유동성	6/20 → 5 단원	수준 1 후보 18	4/24 16.7%

A·B·C 의 추천에는 목적·관심·수준·기기와 학습 상태를 사용했다. B 의 인정 단원 13 개 중 목적 로드맵에 포함되는 단원은 10 개이고, C 는 5 개 중 4 개다. 진행률은 해당 로드맵 안의 인정 단원 수를 전체 로드맵 단원 수로 나눈 값이다. 상세 문항 답안은 부록에 제시한다.

표 4 진단 직후 실제 추천 목록

사용자	순위와 단원	후보와 진행률	현재 단계 정합
A	1 분산투자의 기초 2 연금계좌에서 ETF 투자하기 3 ETF 거래량과 유동성 [현재 단계] 4 국내 상장 해외 ETF 와 해외 상장 ETF [현재 단계] 5 채권 ETF 기초	18 개 24.0%	2 / 5
B	1 옵션 프리미엄과 분배금의 원천 2 분배금 지급 구조와 재투자 3 ETF 거래량과 유동성 [현재 단계] 4 채권 ETF 기초 5 국내 상장 해외 ETF 와 해외 상장 ETF [현재 단계]	23 개 43.5%	2 / 5
C	1 ETF 거래량과 유동성 [현재 단계] 2 섹터 ETF 기초 3 레버리지·인버스 ETF 란 [현재 단계] 4 국내 상장 해외 ETF 와 해외 상장 ETF [현재 단계] 5 원자재 ETF 기초	18 개 16.7%	3 / 5

표 5 공통 위험 기초 이수 후 실제 추천 목록

사용자	순위와 단원	후보와 진행률	현재 단계 정합
A	1 분산투자의 기초 [현재 단계] 2 연금계좌에서 ETF 투자하기 [현재 단계] 3 채권 ETF 기초 [현재 단계] 4 환헤지형과 환노출형 ETF 비교 [현재 단계] 5 ISA 유형·납입 한도·의무가입 기간 [현재 단계]	19 개 44.0%	5 / 5
B	1 옵션 프리미엄과 분배금의 원천 [현재 단계] 2 분배금 지급 구조와 재투자 [현재 단계] 3 해외 ETF 거래 방법과 환전 4 채권 ETF 기초 [현재 단계] 5 리츠 ETF 기초 [현재 단계]	22 개 56.5%	4 / 5
C	1 호가 스프레드 읽기 [현재 단계] 2 섹터 ETF 기초 [현재 단계] 3 변동성 장세의 레버리지 위험과 거래 요건(사전교육·기본예탁금) 4 ESG ETF 란 5 해외 ETF 거래 방법과 환전	20 개 41.7%	2 / 5

공통 기초는 모든 목적의 로드맵에 포함하는 위험 교육 과정이다. 후보 자격은 명시된 선수 관계와 수준 조건으로 판단하고, 현재 단계 가산점으로 학습 순서를 우대한다. 후보 자격을 갖춘 후속 단계나 로드맵 밖 단원도 추천할 수 있다. 표 4·5 는 이 우대 규칙에 따른 실제 목록과 현재 단계 정합 개수를 함께 보여 준다.

A 의 진단 직후 진행률은 6/25 단원으로 24.0%다. 인정된 단원 중 공통 기초는 네 개다. 공통 기초의 나머지 다섯 개를 추가 이수한 상태에서는 11/25 로 44.0%가 된다. 표 5 는 이 추가 이수 상태를 입력한 모의 사례다.

A 의 진단 직후 1 위인 분산투자의 기초는 총점 11.8079 다. 전체 인기 3.6079, 관심 3, 수준 일치 2, 목적 친화도 1.8, 로드맵 단계 1.4, 모바일·짧은 콘텐츠 0 의 합이다. 이때 현재 단계는 공통 기초이고 자산배분은 후속 학습 가능한 단원이므로 로드맵 가산점은 2×0.7=1.4 다. 항목별 기여를 통해 추천 순위의 산출 이유를 설명할 수 있다.

2.5 기대효과

기대효과는 설계로 보장되는 동작과 실사용 자료로 검증할 가설로 나눈다. 선수 위반 0%, 교육용 고지의 상시 노출, 성별 값 변경에 대한 운영 순위의 불변성은 기능·정책 준수 항목이다. 학습 지속, 노출의 공정성, 교육 안내의 이해 가능성은 파일럿에서 확인할 효과 가설로 둔다.

66 단원 전체의 고정 분량을 공통 출발점으로 두고, 목적 로드맵 밖의 분량과 진단으로 인정한 분량을 구분한다. 이 산술 차이는 설계상 이수 대상의 감소를 나타낸다. 동일한 학습 목표에 도달하는 실제 시간과 이해도, 중복 학습 부담은 별도 관측으로 평가한다.

학습자는 목적과 관련된 개념을 이해하고 다음 학습 대상을 고르는 부담이 줄어드는 편익을 기대할 수 있다. 교육 서비스는 진단·오답 기록으로 설명이 부족한 단원을 찾을 수 있다. 사회적 편익은 투자자가 상품 구조를 이해한 상태에서 의사결정하도록 돕고 불완전판매 피해 위험을 낮추는 데 기여한다는 가설이다.

표 6 설계로 보장되는 동작과 검증할 가설

구분	설계로 보장되거나 계산되는 것	파일럿과 후속 시험에서 검증할 가설
선수 학습 지원	필수 선수 미충족 단원을 추천에서 제외해 위반 0%를 유지한다.	이수 순서가 이해·학습 지속에 도움이 되는지 파일럿 기록으로 확인한다.
중복 학습 부담	목적 경로 밖의 분량과 진단 인정 단원의 분량을 나누어 이수 대상 감소를 제시한다.	동일한 학습 목표에서 실제 소요 시간·불필요한 반복이 줄어드는지 관찰한다.
목적에 맞는 경로	목적·로드맵 가산점을 고정하고 목적별 현재 단계 정합률을 계산한다.	목표에 필요한 개념의 충분성을 독립 검수와 사용자 기록으로 확인한다.
위험 통제	교육용 고지를 표시하고 학습 정보와 콘텐츠 속성으로 운영 순위를 구성한다.	안내의 이해 가능성과 목적·이력에 따른 노출 분포를 검토한다.

표 7 고정된 66 단원 전체 기준과 목적별 분량의 분해

사용자	전체 기준 분	목적 과정 분	범위 차이 분	진단 인정 분	잔여 분
A	794	284	510	76	208
B	794	268	526	115	153
C	794	276	518	46	230

전체 794 분은 66 단원에 짧은 단원 8 분·그 외 15 분을 부여해 계산한 카탈로그 예상치다. 목적 과정은 A·B·C 별로 284·268·276 분이며, 각 과정에서 진단으로 인정한 분량을 빼 잔여 분량을 구했다. 표 7 은 목적별 학습 범위와 이수 인정의 산술적 차이를 보여 준다. 실제 시간 절감 효과는 동일한 학습 목표를 달성하는 데 걸린 시간을 파일럿에서 측정해 평가한다.

3 활용 데이터와 확보 계획

3.1 필요한 데이터 항목과 예시

현재 실험은 seed 42 의 모의 학습자 15,000 명·4 주·학습 시도 109,674 건을 사용한다. 완료 50,805 건, 퀴즈 시도 35,448 건, 퀴즈 통과 24,401 건, 저장 12,570 건, 이탈 표시 47,157 건이다. 플래그는 중복되므로 항목별로 집계한다. 서로 다른 사용자–단원 관측은 97,662 쌍이며 사용자당 평균 약 6.51 개다. 행렬 밀도는 9.86%이고, CF 에 필요한 공동 관측의 충분성은 개별 사용자·단원 쌍을 기준으로 살핀다.

표 8 필요한 항목과 모의 행 예시 및 용도

자료	필요한 항목	예시와 확보 형태	용도
초기 학습 정보	가명 ID·목적·기간·위험성향·관심·기기·진단 수준·인정 단원	모의 user=2389, goal=diversify, horizon=mid, placement=3. 실제 수집은 필요 항목만 동의 후 입력	운영 추천과 로드맵 입력
선택 정보와 공정성 점검용 정보	연령·소득 구간·성별	모의 자료의 공정성 점검용 정보. 소득 구간은 필요할 때 세제 설명용으로만 선택 수집	운영 점수에서 제외

자료	필요한 항목	예시와 확보 형태	용도
학습 행동 로그	사용자·단원·세션·시도 시각·완료·퀴즈·통과·저장·이탈	모의 user=2389,item=39,week=1,complete=1,quiz_pass=0,save=1 → 시도 점수 3	관심 특징과 관측 통과 정답
진단 인정	문항별 응답·판정 수준·중복 AND 판정·인정 단원·진단 시각	같은 단원 두 문항 모두 정답일 때 1 개 인정. 규제 문항은 수준 판정용	후보·선수 상태에 반영, 행동 로그와 분리
콘텐츠 카탈로그	단원 제목·주제·수준·분량·선수·출처	item=41, 괴리율이 커지는 상황 이해하기, 수준 3, 선수 40·1	후보·특징·로드맵·설명
외부 메타데이터	기관·URL·이용 조건, ETF 종가·NAV·거래량 등	공식 교육 링크, 유형 카드의 기준일 표시 통계	교육 카드 내용·예시용, 추천 모델에서 제외

목적·기간·위험성향·관심·진단·학습 이력은 초기 추천과 경로에 사용한다. 연령·소득·성별은 운영 점수에서 제외한다. 소득은 ISA 유형·세제 설명에 필요한 경우에만 선택적 구간 정보로 수집하며, 파일럿의 수집 항목도 해당 용도에 따라 정한다.

3.2 확보 방법

11 월 파일럿은 동의한 참여자 20 명 모집을 목표로 하며, ETF 기초 학습이 필요한 집단과 구조·계산 수준 집단을 각 10 명씩 확보하려고 한다. 실제 모집 수와 수준 분포를 함께 보고한다. 금융 MBA 학생 중심의 편의표본은 일반 앱 사용자와 금융 지식·학습 동기가 다를 수 있으므로, 결과의 적용 범위는 참여 집단의 사용성·기능 점검으로 한정한다.

단원은 공식 교육 자료의 제목·주제·수준·선수·출처 키를 직접 검수해 구성한다. 전국투자자교육협의회, 금융투자교육원, 한국거래소 등의 링크와 메뉴 경로를 연결하고 이용 조건을 확인한다[2][3]. ETF 종가·NAV·거래량은 공식 파일·API 에서 확보해 유형 카드의 기준일 표시 예시와 통계에만 활용할 계획이다. 추천 점수 모델의 입력은 학습 정보와 콘텐츠 속성으로 구성한다.

3.3 사용자 반응의 해석

완료도 이탈 표시도 없는 11,712 건은 미완료·이탈 미표시 상태다. 생성기는 미완료 시도의 약 80% 에만 이탈 플래그를 부여한다. 이 상태에는 진행 중·종료 미기록·자발적 중단의 구분을 위한 추가 정보가 필요하다. 파일럿에서는 시작·완료·명시 중단·타임아웃을 구분해 해석의 정확성을 높인다.

한 번의 학습 시도는 조회가 존재하는 행이다. 반응 점수는 조회 1, 완료 2, 퀴즈 통과 3, 저장 3 중 최댓값이고, 같은 단원의 여러 시도는 합산한다. 세션 이벤트가 여러 행이면 사용자·단원·세션을 묶어 한 시도로 만든 뒤 계산한다. 퀴즈 통과⇒퀴즈 시도⇒완료, 이탈⇒미완료의 논리 제약도 검사한다.

조회는 열어 보았지만 이해 여부는 모르는 약한 관심, 완료는 단원을 끝까지 학습한 참여로 본다. 저장은 관심 신호로 사용하고 이수 여부는 퀴즈 통과로 판정한다. 퀴즈 미통과는 완료에 따른 기본 2 점이고 저장이 동반되면 3 점이다. 이탈 자체는 선호 점수에 가감하지 않으며, 미관측은 선호를 알 수 없는 상태로 해석한다. 좋아요·별점은 만족·재미와 학습 성취가 다를 수 있고 응답도 희소할 수 있어 주 라벨로 쓰지 않으며, 학습 정답과 구분되는 만족도 정보로 다룬다.

진단 인정과 학습 행동은 별도로 관리한다. 진단으로 통과가 인정된 단원은 후보·선수 상태에 반영하며, 행동 기반 조회 수·저장·관심 주제 비중·통과율은 실제 학습 기록으로 산출한다. 학습 후 퀴즈 통과는 숙련의 대리 라벨이며 추측 정답·문항 난이도·재노출의 영향을 받을 수 있다. 문항의 개념 범위와 정답 근거를 검수하고 진단 인정의 학습 목표 대표성을 파일럿에서 확인한다.

저장 가중치와 반복 합산은 반응을 수치화하기 위한 설계 가정이다. 가중치와 이수 인정 규칙의 민감도를 각각 점검하고, 실제 관심·어려움과의 대응은 파일럿 자료로 검토한다. 사용자 가명과 원본 매핑은 분리하고 모형·반출 자료에는 필요한 최소 구간만 남긴다.

4 적용 기법 및 비교 방법

4.1 적용 기법

적용 기법은 목적 단계 규칙이다.

운영 점수는 전체 인기의 행별 최소–최대 정규화 값에 관심 주제·수준 일치·모바일용 짧은 콘텐츠·목적 친화도·로드맵 단계 점수를 더한다. 목적과 로드맵 항은 정책 변경 시에도 유지하는 고정 요소다. 연령대·소득분위별 인기와 인구통계 유사도는 운영 점수에서 제외한다. 사용자의 목적은 실제 순위 식과 평가 지표에 반영한다.

전체 인기의 후보 점수가 모두 같으면 정규화 값은 0 으로 둔다. 관심·수준·기기 신호는 0 또는 1 이고 목적 친화도는 템플릿의 0~1 값이다. 로드맵 점수는 현재 단계에서 학습 가능한 단원 1, 후속 단계에서 가능한 단원 0.7, 잠긴 단원 0.4, 로드맵 밖 0 이다. 잠긴 단원은 서비스의 선수 필터에서 제외된다. 가중치와 친화도는 전문가 검수와 파일럿에서 타당성을 확인할 설계 가정이다.

서비스에서는 모든 기법에 공통 수준·선수 필터를 후처리로 적용한다. 이미 통과한 단원과 현재 수준보다 두 단계 이상 높은 단원은 제외하고, 한 단계 위 단원은 최대 하나만 표시한다. 미이수 선수가 있는 단원은 배제하며, 다섯 개가 안 되면 가능한 개수와 남은 조건을 안내한다.

운영 점수 = 5×정규화 전체 인기 + 3×관심 + 2×수준 일치 + 1×모바일·짧은 콘텐츠 + 2×목적 친화도 + 2×로드맵 단계

관심 점수에는 사용자가 직접 입력한 주제를 반영하고, 학습 행동이 쌓이면 행동에서 구한 선호 상위 주제를 추가한다. 목적·단계 점수는 다른 신호와 합산되므로, 최종 순위에 반영된 정도를 정합률과 사용자별 목록으로 확인한다.

4.2 선정 이유

선정 이유의 우선순위는 첫째 진단·목적만으로 즉시 시작할 수 있고, 둘째 가산점 단위로 추천 이유를 설명할 수 있으며, 셋째 수준·선수 제약과 결합하기 쉽다는 설계 적합성이다. 검증에서 NDCG 가 가장 높았던 검증 선택 규칙은 인구통계 집단 인기를 기준 점수로 쓰고 로드맵 단계 항이 없어, 인구통계 배제와 목적·로드맵 항 유지라는 요건을 충족하지 못하므로 운영안으로 쓰지 않는다. 모의 비교는 공통 조건에서 추천 절차와 출력 특성을 점검하는 데 사용한다.

4.3 비교 기준 방법

비교군은 전체 인기, 행동 집단 인기, 검증 선택 규칙, 콘텐츠 기반, 순수 사용자 CF, 아이템 CF, MF(ALS·BPR), MLP 다. 검증 선택 규칙은 규칙 기반 후보 설정 중 2 주차 검증 NDCG 가 가장 높은 설정이며 인구통계 집단 인기를 기준 점수로 쓰고 로드맵 단계 항이 없다. seed 42 설정에는 목적 항도 없다. 사용자 CF 의 인구통계 혼합 비중 w=0 은 행동 유사도만 사용한다는 뜻이다. 비교군의

설정은 검증에서 정하고 3 주차 테스트에서 평가한다. 운영안인 목적 단계 규칙의 가중치는 별도의 설계값으로 고정하며, 모든 방법을 동일 정답·후보·후처리 조건에서 비교한다.

MF 는 암묵 피드백 ALS[4]와 BPR 손실(Rendle 외, 2009)로, MLP 는 임베딩과 은닉층 하나로 학습하며 설정은 2 주차 검증 NDCG 로 정한다. 실제 파일럿 기록에서의 비교는 기말보고서에 포함한다.

콘텐츠·순수 사용자 CF·아이템 CF 는 무이력에서 프로필이나 학습 반응 점수가 모두 0 이 될 수 있다. 별도 인기 대체를 적용하지 않는 기본형은 동점일 때의 고정 순서로 목록을 산출한다. 무이력 성능은 초기화·대체 정책의 필요성과 함께 해석하며, 서비스의 초기 추천에는 진단과 명시적 관심 정보를 사용한다.

표 9 동일 후보와 선수 필터에서의 두 핵심 지표

방법	seed 42 NDCG	현재 단계 정합	새 seed NDCG	현재 단계 정합
목적 단계 규칙 운영안	0.103070	63.40%	0.122274	62.12%
전체 인기	0.100642	63.77%	0.117224	62.76%
행동 집단 인기	0.100797	63.77%	0.117344	62.76%
콘텐츠 기반	0.094280	56.68%	0.109821	57.58%
사용자 CF 행동만	0.098758	62.82%	0.115218	61.72%
아이템 CF	0.098931	63.81%	0.114966	62.62%
MF(ALS)	0.099291	62.99%	0.117096	62.10%
MF(BPR)	0.099231	62.54%	0.117004	61.25%
MLP	0.098814	63.13%	0.117326	62.76%
검증 선택 규칙	0.108794	61.53%	0.126179	59.95%

seed 42 의 평가 대상자는 6,544 명, seed 20261023 의 평가 대상자는 6,487 명이다. 두 집단 모두 현재 단계가 공통 기초여서 표 9 의 정합률은 공통 기초의 결과를 나타낸다. 평가 대상자 전원이 공통 기초 9 단원을 이수했다고 가정해 다음 단계로 옮기면, 정합률은 seed 42 에서 운영안 53.3%, 전체 인기 39.0%, 아이템 CF 34.1%, 검증 선택 규칙 28.2%이고, 새 seed 에서 운영안 51.0%, 검증 선택 규칙 38.8%, 전체 인기 31.5%다(같은 표시 개수의 최대치 62.9%·63.3%). 실제 목적별 핵심·심화 단계는 파일럿에서 단계별로 평가할 계획이다. 표 5 는 공통 기초를 이수한 상태의 사용자별 추천 사례다.

운영안에서 현재 단계와 후속 단계의 로드맵 가산점 차이는 $2\times(1-0.7)=0.6$ 점이다. 반면 목적 친화도는 최대 2 점, 관심은 3 점이어서 목적에 맞는 후속 단계 단원이 현재 단계 단원보다 앞설 수 있다. 표 4 의 A·B 1·2 위가 이러한 사례다. 이는 현재 단계 집중도와 목적 관련성 사이의 상충을 보여 주며, 표 9 에서 공통 기초 기준의 정합률이 인기보다 약간 낮게 나타난 결과와도 일치한다. 목적 반영의 효과는 공통 기초 이후의 목록인 표 5 와 앞의 이수 가정 결과로 확인하고, 파일럿에서 단계별로 다시 평가한다.

목적 단계 규칙은 전체 인기와 MF·MLP 보다 NDCG 가 높다. 검증 선택 규칙과 비교하면 seed 42 의 NDCG 는 0.005724 낮고 정합률은 약 1.9%p 높다. 운영안은 목적 반영·설명 가능성·개인 입력의 교육적 용도를 우선해 선정했다. 향후 교체 후보도 이 요건을 충족한 상태에서 4.4 절의 정책 변경 기준에 따라 평가한다.

검증 선택 규칙은 인구통계 기반 집단 인기 등을 포함한 규칙 기반 후보 중 검증 구간의 NDCG 가 가장 높은 설정이다. 목적 단계 규칙은 별도로 고정한 운영안이다. 사용자 CF 의 인구통계 혼합 비중 w=0 은 행동 유사도만 사용함을 뜻하며, 행동 집단 인기는 조회 활동 구간으로 사용자를 구분한다.

4.4 예상 한계와 개선 방향

seed 42 의 고정 정답 5,826 개 중 4,162 개, 약 71.4%는 추천 직전에 선수가 충족되지 않았다. 모의 관측 로그에는 추천 서비스의 선수 정책이 적용되지 않아, 서비스 제약을 지키는 목록에서는 이 정답들이 후보에서 제외된다. 이 차이는 NDCG 를 낮추는 요인이다. 정답과 IDCG 를 고정해 정책 제약의 영향과 예측 성능을 함께 해석한다. 또한 모의 응답 생성기와 규칙 기반 방법은 목적·수준 등의 변수를 공유하므로, 상대 성능은 생성 가정의 영향을 받는다. 다만 생성기의 목적 효과를 0 으로 둔 seed 42 에서도 운영안의 NDCG@5 는 전체 인기보다 0.0035 높았다(95% 구간 0.0015~0.0054).

진단 인정이 없는 모의 데이터에서 테스트 사용자의 짧은 목록 비율은 52.0%다. 모의 무이력은 행동과 진단 인정이 모두 없는 상태이며, 실제 서비스는 진단 후 추천을 시작한다. 진단 인정은 선수 해제와 인정 단원 제외를 동시에 일으키므로 후보 수에 미치는 방향이 달라질 수 있다. 진단 인정과 수준 갱신을 함께 적용한 민감도 결과를 별도로 제시한다.

모의 진단은 수준별 정답 확률을 정한 가정에 기반한다. 실제 서비스의 짧은 목록 비율은 파일럿에서 진단 직후 후보 수와 함께 측정한다. 그 분포에서 후보 부족이 지속될 경우 입문 단원 추가를 검토하고, 카탈로그 변경의 효과는 실제 응답과 후속 학습으로 평가한다.

단원이 66 개로 적고 일부 사용자의 후보는 4 개 안팎이므로 정렬만 바꾸어 얻을 수 있는 가치가 제한된다. 공통 기초에서는 목적별 목록 차이도 작다. 추천 다양성과 목적·현재 단계의 정합성 사이에는 상충이 있을 수 있다. 필수 학습을 유지하면서 동일 주제 연속 노출을 보조적으로 살피고, 퀴즈 품질과 이수 인정의 타당성을 우선 검증한다.

공정성 평가는 목적·관심·학습 이력을 고려한 집단별 노출 분포를 중심으로 수행한다. 성별 값 변경 검사는 운영 점수의 직접 사용 여부를 확인하는 기능 점검이며, 집단별 차이는 후속 자료에서 수준·목적·이력 조건과 함께 분석한다.

표 10 진단 이수 인정 가정에 따른 짧은 목록 민감도

조건	5 개 미만 사용자	전체 비율	무이력 928 명 비율	목적 단계 진입
진단 인정 없음	3,403/6,544	52.00%	100.00%	0 명
낮은 정답확률 가정	132/6,544	2.02%	2.69%	1 명
중간 정답확률 가정	33/6,544	0.50%	1.08%	1 명
높은 정답확률 가정	9/6,544	0.14%	0.00%	2 명

동일한 6,544 명에게 진단 전 수준과 독립 난수로 20 문항의 모의 응답을 생성하고, 중복 문항의 AND 판정과 이수 인정 규칙을 적용했다. 세 정답확률 가정은 부록에 제시한다. 진단 이수 인정은 후보와 평가 정답 집합을 함께 바꾸므로, 표 10 은 가정별 추천 가능 개수의 민감도 분석으로 해석한다.

진단 문항이 공통 기초 전체를 검사하지 않아 진단 후에도 6,542~6,543 명이 공통 기초 단계에 남았다. 표 10 의 짧은 목록 감소는 일부 선수 조건이 열리는 구조를 보여 준다. 실제 서비스의 입문 단원 추가 여부는 파일럿에서 측정할 진단 후 후보 분포와 콘텐츠 검수 결과로 결정한다.

향후 교체 후보는 목적·로드맵 항을 유지하고, 새로 확보한 자료에서 현 운영안 대비 NDCG@5 의 절대 증가가 0.005 이상이며 목적·현재 단계 정합률이 낮아지지 않고 선수 위반이 0 인 경우에 교체를 검토한다. 그보다 작은 차이는 현 규칙을 유지한다. 0.005 는 변경 비용과 작은 차이의 과대해석을 고려한 운영 기준이다.

정책 변경 판단에는 정책을 고정한 뒤 수집한 새 기간 자료를 사용한다. 후보 탐색이 필요하면 자료를 학습·검증·확인 구간으로 나누고 검증 구간에서 후보를 선택한 뒤 확인 구간에서 성능을 평가한다. 개발 과정에서 사용한 seed 42 자료와 신규 확인 자료의 역할을 구분한다.

5 평가 계획

5.1 평가 지표와 선택 이유

주 평가 지표는 NDCG@5 와 목적·현재 단계 정합률 두 개다. NDCG@5 는 다음 평가 주차에 관측된 통과 단원을 상위에 두었는지, 정합률은 표시한 단원이 현재 목적별 학습 단계와 맞는지를 평가한다. NDCG@5 는 예측 정확도만 보므로, 문제 정의의 핵심인 목적과 학습 순서가 실제 목록에 반영되는지를 정합률로 따로 확인한다. 선수 미충족 비율은 0%를 유지해야 하는 서비스 제약 준수 점검으로 관리한다.

NDCG 의 사용자별 DCG 는 상위 다섯 순위의 이진 적중을 $\log_2$(순위+1)로 할인해 더한 값이다. IDCG 는 동일 사용자의 고정 정답 수와 5 중 작은 개수까지 이상적으로 적중했을 때의 할인 합이다. NDCG=DCG/IDCG 이며 정답이 없으면 0 이다. Hit 은 적중 여부, Precision 은 적중 비율을 중심으로 평가하므로, 상위 적중의 순서까지 반영하는 NDCG 를 첫 지표로 선택한다.

정답은 추천 직전에 미통과이고 수준 후보에 속하는 단원 중 평가 주차에 퀴즈를 통과한 서로 다른 단원이다. 이전 주에 이미 통과한 단원의 재통과는 제외하고 같은 주 중복 통과는 하나로 센다. 선수 필터는 후보에 적용하며 정답과 IDCG 는 고정한다. 한 단계 위 최대 하나는 표시 목록에 적용하는 제약이다. 짧은 목록은 빈칸의 이득을 0 으로 두고 k=5 의 분모를 유지한다.

목적·현재 단계 정합률은 목적 로드맵에서 첫 미완료 단계에 포함되고 학습 가능한 단원이 실제 표시 목록에서 차지하는 비율이다. 공통 기초 단계와 목적별 핵심 이후 단계의 사용자를 나누어 제시한다. 이 지표는 로드맵 기준에 대한 출력 일관성을 나타내며, 목적별 개인화의 차이는 해당 단계의 목록으로 살핀다. 교육적 적합성과 학습 효과는 독립 전문가 검수와 실사용 자료로 검증한다.

표 11 두 핵심 지표의 분모와 해석

주 지표	집계와 예외 처리	선택 이유와 한계
NDCG@5	사용자별 고정 정답·k=5 의 IDCG 로 정규화한 값을 평균한다. 정답이 0 개인 사용자와 빈 순위도 0 점으로 처리한다.	상위 순위에 관측 통과를 두는 품질을 평가한다. 결과 해석에는 미노출·미관측과 생성기 편향을 고려한다.

주 지표	집계와 예외 처리	선택 이유와 한계
목적·현재 단계 정합률	정합 단원 수/실제 표시 단원 수의 마이크로 평균이다. 빈칸은 표시 분모에서 제외하고 추천 결과가 0 개인 요청 수를 별도로 공개한다. 표시 수·짧은 목록 비율을 함께 점검한다.	목적별 현재 단계와 출력의 일관성을 평가한다. 교육적 적합성은 별도의 독립 검수로 확인한다.

정합률은 전체 표시 단원 수를 분모로 집계하며, 사용자별 평균은 보조 분석에 사용한다. 두 seed 의 모든 요청에는 한 개 이상이 추천됐다. seed 42 에서 표시 개수를 동일하게 유지하고 수준 조건을 적용한 정합률의 최대치는 약 64.6%이며 운영안은 63.40%다. 이 최대치는 해당 후보와 표시 개수를 전제로 한 조건부 값이다.

5.2 평가 데이터와 절차

시간 분할은 0~1 주 자료로 모델 훈련 → 2 주차 검증·비교군 설정 고정 → 0~2 주 자료로 재훈련 → 3 주차 평가다. 추천에는 추천 시점까지의 학습 기록을 사용한다. seed 42 의 검증 대상은 2 주차에 시도가 있는 6,685 명, 테스트 대상은 3 주차 시도가 있는 6,544 명이다. 이 대상은 전체 15,000 명 및 향후 A/B 의 전체 배정자와 구분한다.

seed 42 에서 고정 정답을 하나 이상 가진 사용자는 3,542 명으로 테스트 시도자의 54.1%다. 정답이 없는 3,002 명도 NDCG 0 으로 전체 평균에 포함하고, 정답 보유자 평균은 보조값으로 명시한다. 평가의 분모는 사용자 단위로 유지하며 시도 단위 통과율과 구분한다.

방법 간 NDCG 차이의 구간은 같은 사용자의 방법별 점수를 함께 재표집하는 대응 부트스트랩으로 계산한다. 500 회 2.5·97.5 백분위 구간은 고정된 모의 세계에서의 사용자 변동을 반영한다. 생성 가정·설정 탐색·다중 비교의 불확실성은 별도로 고려해야 하며, 많은 설정 중 검증 최고값에는 선택 편향이 있을 수 있다.

새 seed 의 반복 실행은 동일한 생성 규칙 아래에서 고정 정책과 추천 절차의 작동을 확인하는 민감도 점검이다. 독립적인 실사용 검증은 정책 동결 후 11 월 파일럿에서 수집할 진단·학습 로그로 수행한다. 모의 반복 결과와 실사용 결과는 자료의 생성 방식에 따라 구분해 보고한다.

학기 내에는 11 월 1 주에 단원·문항·출처와 운영 정책을 동결하고, 11 월 2~3 주에 목표 20 명의 동의를 받아 진단과 추천·학습을 기록한다. 11 월 4 주에 이수 인정의 과도한 면제, 설명의 이해 가능성, 후보 부족을 검토하고 12 월 기말보고서에 반영한다. 참가자 중 7 일 안에 학습 후 퀴즈를 하나 이상 통과한 비율을 탐색적으로 관측한다. 결과의 적용 범위는 소규모 편의표본의 특성에 맞춰 해석한다.

충분한 유입이 확보되면 목적 단계 규칙과 고정 비교안을 사용자 단위로 무작위 배정한다. 분모는 모든 배정자이며, 통제군의 사용자 기준율은 실제 자료에서 산정한다. 사용자 7 일 통과율의 기준율과 효과 크기는 시도 단위 약 22%의 통과율 및 모의 NDCG 차이와 구분해 추정한다.

기준율이 미정이므로 표본은 가정별 범위로 제시한다. 양측 5%·검정력 80%·동일 배정의 두 비율 근사에서 기준율 10~40%, 개선 1~2%p 이면 군당 약 3,841~37,827 명이 필요하다. 이는 이탈·다중 지표·반복 확인 보정 전의 예산 검토 값이다. 목표 20 명 파일럿은 사용성과 측정 절차를 점검하고, A/B 효과 검증은 충분한 표본이 확보되는 후속 단계에서 수행한다.

정합률의 교육적 타당성을 검토하기 위해 파일럿 전에 목적·선행 지식만 제시한 사례를 교육 검토자에게 독립적으로 평가받는다. 검토 결과에 따라 로드맵 밖의 필수 단원과 현재 단계의 부적절한 단원을 조정한다. 사용자의 학습 목표 이해와 알고리즘의 규칙 준수는 각각 독립된 평가 대상으로 보고한다.

표 12 기준율과 목표 차이 가정별 A/B 시험의 군당 표본

사용자 7 일 통과 기준율 가정	개선 1%p	개선 2%p
10%	14,751 명	3,841 명
22%	27,372 명	6,950 명
40%	37,827 명	9,493 명

표 12 는 사용자 기준율 10%·22%·40%를 가정한 예산 시나리오다. 실제 기준율은 파일럿의 사용자별 7 일 통과 기록으로 추정한다. 표본 식은 독립 사용자와 정규 근사를 전제로 하므로 재참여·실험 간 간섭·이탈을 고려해 최종 설계를 조정한다.

참고 자료

[1] 금융위원회. 단일종목 레버리지 상품(ETF·ETN) 투자시 유의사항 안내. 2026 년 5 월 26 일. https://www.fsc.go.kr/no010101/86973 (2026 년 10 월 23 일 확인).

[2] 전국투자자교육협의회 ETF 스쿨·연금 스쿨. https://www.kcie.or.kr/elearning/etf/etfList ; https://www.kcie.or.kr

[3] 금융투자교육원. https://www.kifin.or.kr ; 한국거래소. https://www.krx.co.kr ; 금융위원회 증권상품시세정보. https://www.data.go.kr/data/15094806/openapi.do

[4] Hu, Y., Koren, Y., Volinsky, C. (2008). Collaborative Filtering for Implicit Feedback Datasets. https://yifanhu.net/PUB/cf.pdf

[5] 인공지능과추천시스템 수업 교안·실습 1~7 주 및 9 주.

부록 진단 사례와 민감도 분석

진단 문항의 답안과 인정 차이

표 A1 동일한 20 문항에 대한 세 사용자의 보기 번호와 판정

문항	A	B	C	용도
q01	1 정답	1 정답	1 정답	이수 판정
q02	4 정답	4 정답	4 정답	이수 판정
q03	4 오답	3 정답	4 오답	이수 판정
q04	1 정답	1 정답	2 오답	이수 판정
q05	4 오답	3 정답	4 오답	이수 판정
q06	4 정답	4 정답	4 정답	이수 판정

문항	A	B	C	용도
q07	2 정답	2 정답	2 정답	이수 판정
q08	3 정답	4 오답	4 오답	이수 판정
q09	1 오답	4 정답	1 오답	이수 판정
q10	2 오답	1 정답	2 오답	이수 판정
q11	3 오답	2 정답	3 오답	이수 판정
q12	1 오답	4 정답	1 오답	이수 판정
q13	2 오답	2 오답	2 오답	이수 판정
q14	3 오답	3 오답	3 오답	이수 판정
q15	4 오답	3 정답	3 정답	이수 판정
q16	3 오답	3 오답	3 오답	이수 판정
q17	1 정답	1 정답	2 오답	이수 판정
q18	4 오답	4 오답	4 오답	이수 판정
q19	1 오답	1 오답	1 오답	이수 판정
q20	3 오답	3 오답	2 정답	수준 판정만

보기 번호는 1~4 로 표시했다. q08·q19 와 q13·q18 은 각각 같은 단원의 중복 문항으로, 두 문항을 모두 맞혀야 이수를 인정한다. A 는 q08 정답·q19 오답으로 해당 단원을 인정하지 않고, C 가 맞힌 q20 은 수준 판정에 반영한다. 진단 정답 수와 이수 인정 수는 이 규칙에 따라 달라진다.

모의 진단 정답확률 가정

가정	진단 전 수준	문항 수준 1	문항 수준 2	문항 수준 3
낮은 정답확률 가정	진단 전 수준 1	40%	25%	25%
낮은 정답확률 가정	진단 전 수준 2	65%	45%	25%
낮은 정답확률 가정	진단 전 수준 3	80%	65%	45%
중간 정답확률 가정	진단 전 수준 1	60%	30%	25%
중간 정답확률 가정	진단 전 수준 2	80%	60%	35%
중간 정답확률 가정	진단 전 수준 3	90%	80%	60%
높은 정답확률 가정	진단 전 수준 1	75%	45%	30%
높은 정답확률 가정	진단 전 수준 2	90%	75%	50%
높은 정답확률 가정	진단 전 수준 3	97%	90%	75%

모든 문항에 응답한다고 가정하고, 세 시나리오에 같은 균등 난수를 사용해 확률 가정의 차이를 비교했다. 모의 응답은 진단 전 수준과 독립 난수로 생성했다. 추측 정답에 따른 과도한 이수 인정은 실제 응답과 후속 학습 기록을 통해 검토할 과제다.